Obligatorio 1

Matias Repetto - 5.160.290-4
Lautaro Nieves - 5.034.630-3
Agustín Ledesma - 5.445.512-6
Patricio Porcal - 5.320.757-2
Grupo 25 - Tutor: Juan Piccini
Obligatorio 1 - Métodos Numéricos 2021.

24 de septiembre de 2021

Índice

1. Ejercicios 1.1 **3**
1.1. Teoremas . . . 3
1.1.1. Matrices simétricas . . . 3
1.1.2. Matrices semejantes . . . 3
1.2. Ejercicio 1 . . . 3
1.3. Ejercicio 2 . . . 4
1.4. Ejercicio 3 . . . 4

2. Ejercicios 1.2 **4**
2.1. Convexidad . . . 4
2.1.1. Demostrar si Ω es convexo. . . . 4
2.1.2. Demostrar si Γ es convexo . . . 5

3. Ejercicio 2.1.1 **6**

4. Matrices Estocásticas **8**
4.1. Ejercicio 1.3.1.1 . . . 8
4.2. Ejercicio 1.3.1.2 . . . 9
4.3. Ejercicio 1.3.1.3 . . . 9
4.4. Ejercicio 1.3.1.4 . . . 10

5. Ejercicios 1.4 **11**
5.1. Ejercicio 1.4.2 . . . 11

6. Ejercicio 2.2 **12**
6.1. Ejercicio 2.2.1 . . . 12

7. Ejercicios 3 **13**
7.1. Ejercicio 3.1.1 13
7.2. Ejercicio 3.1.1.1 13
7.3. Ejercicio 3.1.1.2 14
7.4. Ejercicio 3.1.3.1 15
7.5. Ejercicio 3.1.3.2 16
7.6. Ejercicio 3.1.3.3 16
7.7. Ejercicio 3.2 17

8. Ejercicios 4 **18**
8.1. Ejercicio 4.1.1 18
8.2. Ejercicio 4.1.2 19
8.3. Ejercicio 4.2.1 20
8.4. Ejercicio 4.2.1 20
8.5. Ejemplo 4.2.2 21

1. Ejercicios 1.1

Antes de comenzar, enunciaremos algunas definiciones útiles que se utilizarán en las demostraciones de esta sección.

1.1. Teoremas

1.1.1. Matrices simétricas

Una matriz $M \in R^{n \times n}$ es simétrica si $M = \mathbf{M}^\intercal$.

1.1.2. Matrices semejantes

Dos matrices A y $B \in R^{n \times n}$ son semejantes si existe una matriz invertible $P \in R^{n \times n}$ tal que: $A = P^{-1}BP$. Una de las propiedades de las matrices semejantes es que tienen los mismos valores propios, es decir, $p_A(\lambda) = p_B(\lambda)$.
Demostración:
Sabiendo que $p_A(\lambda) = \det(A\text{-}\lambda)$, $p_B(\lambda) = \det(B\text{-}\lambda)$ y $A = P^{-1}BP$
$\implies p_A(\lambda) = \det(A\text{-}\lambda I)$
$= \det(P^{-1}BP\text{-}\lambda I)$
$= \det(P^{-1}BP\text{-}P^{-1}\lambda IP)$
$= \det(P^{-1}.(B\text{-}\lambda I).P)$
$= \det(P^{-1}).\det(B\text{-}\lambda I).\det(P)$
$= \det(B\text{-}\lambda I)$
$= p_B(\lambda)$
Donde usamos que $\lambda I = \lambda P^{-1}P = P^{-1}\lambda IP$ y que $\det(P^{-1}) = \frac{1}{det(P)}$.

1.2. Ejercicio 1

Como $\mathbf{Q}^\intercal Q = I \implies Q^\intercal = \mathbf{Q}^{-1}$ Por lo tanto Q es una matriz ortogonal.

Tenemos que $M = \mathbf{Q}^\intercal AQ$ y $\mathbf{Q}^\intercal = \mathbf{Q}^{-1}$, entonces M es semajante a A, por lo tanto M tiene el espectro deseado, y como A es una matriz diagonal llegamos a que M es diagonalizable a travez de A.
Luego, tomando $M = \mathbf{Q}^\intercal AQ$
$\implies M^\intercal = (Q^\intercal AQ)^\intercal$
$\implies M^\intercal = (\mathbf{AQ})^\intercal\ (Q^\intercal)^\intercal$
$\implies M^\intercal = \mathbf{Q}^\intercal A(Q^\intercal)^\intercal$
$\implies M^\intercal = \mathbf{Q}^\intercal AQ = M$
$\implies$ M es simétrica.

1.3. Ejercicio 2

$$\text{Sea M} = R \circ R \Longrightarrow M = \begin{pmatrix} a11 & .. & . & a1n \\ . & .. & . & . \\ . & aii & . & . \\ . & ... & . & . \\ an1 & .. & . & ann \end{pmatrix} \begin{pmatrix} a11 & .. & . & a1n \\ . & ... & . & . \\ . & aii & . & . \\ . & ... & . & . \\ an1 & .. & . & ann \end{pmatrix} \Longrightarrow M = \begin{pmatrix} (a11)^2 & .. & . & (a1n)^2 \\ . & .. & . & . \\ . & (aii)^2 & . & . \\ . & ... & . & . \\ (an1)^2 & .. & . & (ann)^2 \end{pmatrix} (1)$$

Luego, como mij = $(aij)^2$ $\forall$ i,j $\in$ 1...n, tenemos que todos los elementos de la matrix M son siempre mayores o iguales que 0, por lo tanto la matriz M es no-negativa.

Para M simétrica se tiene que $\text{M} = R \circ R \Longrightarrow \text{M}^\intercal = (\mathbf{R} \circ \mathbf{R})^\intercal$
$\Longrightarrow \text{M}^\intercal = \mathbf{R}^\intercal \circ \mathbf{R}^\intercal$
Como $\text{R} = \mathbf{R}^\intercal$ tenemos que $\mathbf{M}^\intercal = R \circ R = \text{M}$, por lo tanto M es simétrica.

1.4. Ejercicio 3

Como Ω es el conjunto de todas las matrices simétricas con el espectro deseado Λ, si tomamos las matrices $\text{M} \in \Omega$ y M no-negativa, tenemos que el conjunto fomrado por las matrices M da como resultado P1, ya que son todas las matrices no-negativas con el espector desado Λ.

2. Ejercicios 1.2

2.1. Convexidad

2.1.1. Demostrar si Ω es convexo.

Ω es el conjunto de matrices simetricas con el espectro deseado.
$\Omega = \{Q^T \Lambda Q : \text{Q} \in \text{R}^{n \times n}, \ \ Q^T Q = I\}$. Donde Λ es una matriz diagonal constante con el espectro deseado.

Demostración:
Un conjunto $\text{C} \subseteq \text{R}^n$ es convexo $\iff \forall\, \Omega_1, \Omega_2 \in C : \lambda\Omega_1 + (1-\lambda)\Omega_2 \in C, \forall \lambda \in [0,1]$ es decir; es convexo si el segmento que une a dos puntos cualesquiera, también pertenece. Entonces sean Ω_1 y $\Omega_2 \in \Omega$, y $\lambda \in [0,1]$, aplicando la definición de conjunto convexo tenemos:

$$\lambda\Omega_1 + (1-\lambda)\Omega_2 = \lambda(Q_1^T \Lambda Q_1) + (1-\lambda)(Q_2^T \Lambda Q_2) = Q_1^T(\lambda\Lambda)Q_1 + Q_2^T(1-\lambda)\Lambda Q_2$$

Este resultado es una matriz simétrica, ya que es producto de la suma de dos matrices simétricas. Pero su suma no necesariamente puede resultar en una matriz que tenga el espectro deseado. En conclusión, Ω no es convexo.

2.1.2. Demostrar si Γ es convexo

Γ es el conjunto de matrices simétricas no-negativas, es decir:
$\Gamma = \{R \circ R : R \in \mathbb{R}^{n \times n}, R = R^T\}$ donde $\circ$ representa el producto Hadamard. ($(A \circ B)_{ij} = (A)_{ij}(B)_{ij}$).

Demostración:
Tomamos Γ_1 y $\Gamma_2 \in \Gamma$ y $\lambda \in [0, 1]$ tales que:
$\Gamma_1 = R_1 \circ R_1$ con $R_1 = R_1^T$
$\Gamma_2 = R_2 \circ R_2$ con $R_2 = R_2^T$
Aplicando la definición de convexidad tenemos que:

$\lambda\Gamma_1 + (1-\lambda)\Gamma_2 = \lambda(R_1 \circ R_1) + (1-\lambda)(R_2 \circ R_2)$ donde $\lambda(R_1 \circ R_1) \in \Gamma$ y $(1-\lambda)(R_2 \circ R_2) \in \Gamma$ pues ambas son matrices simétricas multiplicadas por un escalar y pueden ser escritas de la forma en la que se escribe un elemento de Γ.
El resultado es una matriz simétrica ya que es la suma de 2 matrices simétricas, mas aún, el resultado podria escribirse en la forma $\sqrt{\lambda\Gamma_1 + (1-\lambda)\Gamma_2} \circ \sqrt{\lambda\Gamma_1 + (1-\lambda)\Gamma_2}$. En conclusión, Γ es convexo.

Para las anteriores 2 demostraciones se usó la propiedad de que la suma de matrices simétricas es una matriz simétrica, aquí debajo estará adjuntada la demostración de esta propiedad.
Demostración:

Sea $A \in \mathbb{R}^{n \times n} = (a_{ij})$ tal que $A = A^T$, es decir $a_{ij} = a_{ji}$ y sea $B \in \mathbb{R}^{n \times n} = (b_{ij})$ tal que $B = B^T$, o sea $b_{ij} = b_{ji}$ $\forall i, j$ $1 \leq$ i,j $\leq$ n
Calculamos A+B:
A+B=$(a_{ij} + b_{ij})$=(a_{ij})+(b_{ij})=(a_{ji})+(b_{ji})=$(a_{ji} + b_{ji})$=$A^T + B^T = (A + B)^T$

3. Ejercicio 2.1.1

La resolución de este problema puede ser formulada como encontrar X $\in \Omega \cap \Gamma$, es decir, encontrar matrices simétricas no-negativas con el espectro deseado. Y debemos probar que este es un espacio de Hilbert.
Para probar que es de hilbert, basta mostrar que es completo respecto a la norma frobenius: $|| \ x \ ||=\sqrt{< x, x >}$, donde $< x, x >$ representa el producto interno de una matriz consigo mismo, y se calcula de la forma:
$< A, B >= tr(AB)$.
Ahora, completo respecto a la norma significa que cualquier sucesión de Cauchy de elementos del espacio, converge a un elemento del espacio (esto también implica que es cerrado). Otra implicancia es que la norma de las diferencias tiende a cero. Para probar que es un espacio de hilbert usaremos las siguientes definiciones:

Definición: Sea (X,d) un espacio métrico y $\{X_n\}_n \in \mathbb{N}$ una sucesión en X. $\{X_n\} \in \mathbb{N}$ es de Cauchy si $\forall \ \epsilon > 0 \ \exists_{n0} \in \mathbb{N} : \forall n_1, n_2 \geq n_0$; d$(x_{n1}, x_{n2}) < \epsilon$.

Definición: Un espacio métrico (X,d) es completo si toda sucesión de Cauchy es convergente, es decir:
$X_n \longrightarrow$ X si d(X_n,X) $\overrightarrow{n}$ 0.

Definición: Sea (X,d) un espacio métrico. Una función $\rho : X \longrightarrow X$ es una r-contracción si d$(\rho(x), \rho(y)) < r.d(x, y), 0 < r < 1$.

Definición: sea x$\neq$0. Una métrica o distancia d en X es una función que cumple:
1) d(x,y)$\geq$ 0 y d(x,y)=0 $\longleftrightarrow x = y$
2) d(x,y)=d(y,x) $\forall x, y \in X$
3) d(x,z)$\leq$d(x,y)+d(y,z) $\forall x, y, z \in X$

Definición: Sea (X,d) un espacio métrico completo y $\rho : X \longrightarrow X$ una r-contracción para cierto numero real $0 < r < 1$ y $x_0 \in X$ arbitrario entonces consideremos una sucesion $\{X_n\}_{n\in\mathbb{N}} \subset X$ dada por $X_{n+1} = \rho(X_n)$
Entonces:
1) La sucesion $\{X_n\}_{n\in\mathbb{N}}$ es convergente a α, independientemente de x_0 (siendo α el límite y $\{X_n\}$perteneciente a $\Gamma \cap \Omega$).
2)El elemento $\alpha \in$ X es un punto fijo de ρ, es decir que $\rho(\alpha) = \alpha$
3)α es único.

Usando lo anterior, ahora procedemos a demostrar que es un espacio de Hilbert.

Demostración:
1) Probaremos que ρ es continua.
Sea $\{Z_n\}$ convergente a Z $\in$ X tenemos que d(Z_n, Z) $\overrightarrow{n}$ 0 pero en ese caso
0$\leq$ d$(\rho(Z_n), \rho(Z)) \leq r.d(Z_n, Z)$ $\overrightarrow{n}$ 0.
Luego $\rho(Z_n) \longrightarrow \rho(Z)$ y ρ es continua.

Observación: d(x_2, x_1) = d$(\rho(x_1), \rho(x_0)) \leq$ r.d(x_1, x_0).

Sea m> n : d(x_m, x_n) = d$(\rho(x_0)^m, \rho(x_0)^n) \leq d(\rho(x_0)^n, \rho(x_0)^{n+1}) + d(\rho(x_0)^{n+1}, \rho(x_0)^{n+2})$
+ ... + $d(\rho(x_0)^{m-1}, \rho(x_0)^m)$.

$\longrightarrow$ por r-contracción tenemos: $r^n.d(x_o, x_1) + r^{n+1}.d(x_0, x_1) + ... + r^{m-1}.d(x_o, x_1)$

= $(\sum_n^{m-1} r^i).d(x_o, x_1) = \frac{r^n - r^m}{1-r}.d(x_0, x_1)$
donde $(\sum_n^{m-1} r^i).d(x_o, x_1) \leq (m-n).r^n.d(x_0, x_1)$.

$\sum_{i=a}^{b} r^i = \sum_{i=a}^{\infty} r^i - \sum_{i=b+1}^{\infty} r^i = \frac{r^a}{1-r} - \frac{r^{b+1}}{1-r}$

$\frac{r^n}{1-r}.d(x_0, x_1).(1 - r^{m-n}) \longrightarrow 0$.
Luego $\{X_n\}$ es de Cauchy ya que X es completo, existe $\alpha \in X$ tal que $X_n \longrightarrow \alpha$

2)$\rho(\alpha) = \rho(lim\ _{n\to\infty}\ X_n) = \lim\ _{n\to\infty}\ X_{n+1} = \alpha$.
Luego α es un punto fijo de ρ.

3) Sea β: $\rho(\beta)$=β. Después d(α, β)=$|d(\rho(\alpha), \rho(\beta))| \leq r.d(\alpha, \beta) \longrightarrow 0 \leq (1-r).d(\alpha, \beta) \leq 0$.
Donde (1-r)$\neq$0 y d(α, β)=0 $\longleftrightarrow$ $d(\alpha, \beta) = 0 \longleftrightarrow \alpha = \beta$

En conclusión, X es un espacio de Hilbert.

4. Matrices Estocásticas

Aquí presentaremos las soluciones a los problemas planteados en la seccion 1.3 de la letra del obligatorio.

Empecemos con una pequeña introduccion de conceptos para esta seccion del trabajo:

Matriz estocastica: Una matriz $n \times n$ se dice *Estocastica* si es no negativa en cada una de sus entradas y la suma de las mismas en cada fila es igual a 1.

Valores propios (o Auto-Valores): Sea $A_{n\times n}$, λ es un valor propio de A si existe $x \in \mathbb{R}^n$ con $x \neq 0$ tal que $A * x = \lambda * x$, entonces x es denominado como vector propio asociado al valor propio λ.

Radio espectral de una matriz: El radio espectral de una matriz es el mayor de los valores propios asociados a dicha matriz.

Combinacion convexa: Es una combinacion lineal de puntos en un espacio a fin donde todos los coeficientes son no negativos y suman 1.

4.1. Ejercicio 1.3.1.1

Problema : Sea S una matriz *Estocastica* demostrar que 1 es un valor propio de S.
Demostracion:

Tenemos:

$$S = \begin{bmatrix} a_{11} & . & . & . & a_{1n} \\ . & . & & & . \\ . & & . & & . \\ . & & & . & . \\ a_{n1} & . & . & . & a_{nn} \end{bmatrix}$$

Siendo S una matriz estocastica, esto nos dice que cumple con lo siguiente, $\sum_{j=1}^{n} a_{ij} = 1$ para cada $i \in 1, ..., n$ fijo, ademas todas sus entradas son no negativas.

Entonces, Por la definicion de valor propio tenemos que $\exists x \in \mathbb{R}^n$ con $x \neq 0$ tal que $S * x = \lambda * x$.

Luego usamos por conveniencia el vector propio $x_1 = \begin{pmatrix} 1 & . & . & . & 1 \end{pmatrix}^t$ con n filas y 1 columna, por la singularidad de que S es estocastica tenemos que $S * x_1 = 1$. Luego si $S * x_1 = 1$ entonces $\lambda * \begin{pmatrix} 1 & . & . & . & 1 \end{pmatrix}^t = 1$, por lo tanto $\lambda = 1$, entonces S tiene valor propio $\lambda = 1$.

4.2. Ejercicio 1.3.1.2

Problema: Mostrar que $p(S) = 1$, donde $p(.)$ es el radio espectral.
Demostracion:

Por absurdo diremos $\lambda > 1$ y un vector propio $x \neq 0$ tal que $S*x = \lambda*x$. Sea x_g el elemento mas grande de x por lo tanto el vector propio mas grande, dado que cualquier multiplo escalar de x tambien satisface $S * x = \lambda * x$ entonces podemos suponer que $x_g > 0$ dado que las entradas de S son no negativas y sus filas suman 1 por ser estocastica, entonces cada entrada $\lambda * x$ es una combinacion convexa de los elementos de x. Entonces ninguna entrada en $\lambda * x$ puede ser mayor que x_g. Pero $(\lambda > 1) \Rightarrow (\lambda * x_g > x_g)$ y esto es una contradiccion porque tomamos a x_g como el mas grande, entonces el valor propio mas grande de S es $\lambda = 1$.

Observacion: Si S es una matriz irreducible se puede aplicar el teorema de Perron-Frobenius que dice que toda matriz estocastica irreducible cumple que $|p(S)| = 1$ seindo $p(S)$ el radio espectral da la matriz S. Esto serviria para concluir facilmente 1y2 pero siempre y cuando sea estocastica e irreducible de lo contrario esto no tiene por que ser cierto.

4.3. Ejercicio 1.3.1.3

Problema: Suponga que λ satisface las condiciones anteriores para ser el espectro de S, y que se puede encontrar una matriz A no-negativa con espectro λ. Si x es un auto-vector de A correspondiente al auto-valor 1 con entradas positivas, mostrar que $D^{-1}AD$ es una matriz estocástica con espectro λ, donde $D = diag(x)$.
Demostracion:

Tenemos que λ satisface las condiciones necesarias para ser espectro de S siendo el espectro de S el conjunto formado por valores propios de la matriz. Ademas tenemos que se puede encontrar A no-negativa $(a_{ij} \geqslant 0 \forall ij)$ tal que λ es espectro de A. Luego si x es un auto-vector de A correspondiente al auto-valor 1 con entradas positivas, entonces por definicion de auto-valor tenemos que $(A * x = 1 * x) \Rightarrow (A * x = x)$.

Por otro lado tenemos D tal que $D = diag(x)$ con $x = \begin{pmatrix} x_1 & . & . & . & x_n \end{pmatrix}$, entonces

$$D = \begin{bmatrix} x_1 & 0 & . & . & 0 \\ 0 & . & & & . \\ . & & . & & . \\ . & & & . & 0 \\ 0 & . & . & 0 & x_n \end{bmatrix}$$

siendo $D_{n \times n}$ una matriz triangular superior e inferior. Luego $D^{-1} * A * D$ lo ejemplificamos para matriz $2 * 2$ ya que conserva todas las propiedades para $n * n$ solo que la exigencia es justamente que sea cuadrada.

Sea:

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}, D = \begin{pmatrix} \psi_1 & 0 \\ 0 & \psi_2 \end{pmatrix}, D^{-1} = \begin{pmatrix} 1/\psi_1 & 0 \\ 0 & 1/\psi_2 \end{pmatrix}$$

$$\Rightarrow D^{-1} * A * D = \begin{pmatrix} a_{11} & (\psi_2/\psi_1) * a_{12} \\ (\psi_1/\psi_2) * a_{21} & a_{22} \end{pmatrix}$$

, entonces para que $D^{-1} * A * D$ sea estocastica tenemos que forzar lo siguente:

$$E1 = \begin{cases} a_{11} + (\psi_2/\psi_1) * a_{12} = 1 \\ (\psi_1/\psi_2) * a_{21} + a_{22} = 1 \end{cases}$$

, entonces multiplicamos la fila 1 por (ψ_1) y la fila 2 por (ψ_2) luego $E1$ queda:

$$E1 = \begin{cases} a_{11} * \psi_1 + a_{12} * \psi_2 = \psi_1 \\ a_{21} * \psi_1 + a_{22} * \psi_2 = \psi_2 \end{cases}$$

, como $A * x = x$ y ademas $x = \begin{pmatrix} \psi_1 & \psi_2 \end{pmatrix}^t$, entonces:

$$(A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}) * (x = \begin{pmatrix} \psi_1 \\ \psi_2 \end{pmatrix}) = \begin{pmatrix} \psi_1 \\ \psi_2 \end{pmatrix}$$

$$\Rightarrow E2 = \begin{cases} a_{11} * \psi_1 + a_{12} * \psi_2 = \psi_1 \\ a_{21} * \psi_1 + a_{22} * \psi_2 = \psi_2 \end{cases}$$

Luego como $E2$ se cumple por definicion de auto-valor, entonces $E1$ se cumple, por lo que $D^{-1}AD$ es equivalente a A, entonces es una matriz estocastica con espectro λ.

4.4. Ejercicio 1.3.1.4

La equivalencia es inmediata y trivial ya que las matrices estocasticas son matrices no negativas por definicion, entonces si tenemos manera de resolver a $(P1)$ entonces inmediatamente tenemos manera de resolver $(P1)$ y ademas $(P1)$ se puede tomar como caso particular de $(P1)$.

5. Ejercicios 1.4

5.1. Ejercicio 1.4.2

Se tiene C_1, C_2 subespacios cerrados no vacios de Hilbert.

Esto implica que existe al menos un elemento en C_1 y uno en C_2.

Tomando $y_0 \in C_2$ arbitrario y $x_1 = P_{C_1}(y_0)$, se sabe, por definicion de proyeccion, que $||x_1 - y_0|| \leq ||x - y_0|| \; \forall x \in C_2$.

Luego, tomando $y_1 = P_{C_2}(x_1)$, tambien se cumple $||x_1 - y_1|| \leq ||x_1 - y|| \; \forall y \in C_1$.

En especifico tambien se cumple la ultima desigualdad para $y = y_0 \Rightarrow ||x_1 - y_1|| \leq ||x_1 - y_0||$.

Por ultimo, tomando $x_2 = P_{C_1}(y_1)$, tenemos $||x_2 - y_1|| \leq ||x - y_1|| \; \forall x \in C_2$.

En especifico tambien se cumple la ultima desigualdad para $x = x_1 \Rightarrow ||x_2 - y_1|| \leq ||x_1 - y_1||$.

Juntando las desigualdades $||x_2 - y_1|| \leq ||x_1 - y_1||$ y $||x_1 - y_1|| \leq ||x_1 - y_0||$ tenemos:

$$||x_2 - y_1|| \leq ||x_1 - y_1|| \leq ||x_1 - y_0||. \tag{2}$$

6. Ejercicio 2.2

6.1. Ejercicio 2.2.1

Pseudo Codigo:

Require: $\lambda = \{\lambda_1, \ldots, \lambda_n\}$, con $\lambda_1 \geq \cdots \geq \lambda_n$
1: $Y \in \Gamma$ elegida aleatoriamente.
2: repeat
3: Calcular la descomposición en auto-valores y auto-vectores de $Y : Y = \mathrm{Vdiag}\left(\mu_1, \ldots, \mu_n\right) V^T, \mu_1 \geq \cdots \geq \mu_n$
4: $X := V \operatorname{diag}\left(\lambda_1, \ldots, \lambda_n\right) V^T$. Aqui debemos acomodar los veps y vaps en orden para el calculo.
5: $X := \frac{1}{2}\left(X + X^T\right)$.
6: $Y := X_+$
7: until $\|X - Y\| < \epsilon$

Las posibles desventajas son que el algoritmo para converger debe recibir un vector λ el cual la suma de cada una de sus entradas no se negativo, tambien el orden es un problema ya que la descomposicion de Y ocupa orden $o(n^3)$ y esto puede ser muy costoso para matrices grandes. Luego hay que hacer una reordenacion de los autovectores y autovalores en X lo cuale nos suma mas tiempo de computo a lo ya descrito.

7. Ejercicios 3

7.1. Ejercicio 3.1.1

Sea M = $R \circ R$, por lo demostrado en la sección Ejercicios 1.1 - Ejercicio 1, M es una matriz no-negativa y M $\in \Upsilon$.
Luego, como M $\in \Psi$, existen una matriz unitaria U $\in \mathbb{C}^{n\times n}$ y una matriz triangular superior T $\in \mathbb{C}^{n\times n}$ con diagonal λ tal que M = UTU*.
Entonces, por el teorema 3.1.1 M tiene como espectro diag(T) = λ
Por lo tanto, $\Psi \cap \Upsilon$ está formado por las matrices no-negativas con espectro λ, entonces P1 = $\Psi \cap \Upsilon$.

7.2. Ejercicio 3.1.1.1

$$UT_1U^* = \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ \sqrt{2}/2 & -\sqrt{2}/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 4 \\ 0 & 2 & 2 \\ 0 & 0 & 3 \end{pmatrix} \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ \sqrt{2}/2 & -\sqrt{2}/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} = ... \tag{3}$$

$$... = \begin{pmatrix} \sqrt{2}/2 & 3\sqrt{2}/2 & 3\sqrt{2} \\ \sqrt{2}/2 & -\sqrt{2}/2 & \sqrt{2} \\ 0 & 0 & 3 \end{pmatrix} \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ \sqrt{2}/2 & -\sqrt{2}/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} = ... \tag{4}$$

$$... = \begin{pmatrix} 2 & -1 & 3\sqrt{2} \\ 0 & 1 & \sqrt{2} \\ 0 & 0 & 3 \end{pmatrix} = T_2 \tag{5}$$

Luego:

Como los autovalores λ = 0,0,0, cualquier permutacion de este conjunto es igual a si mismo. Por lo que los valores $\hat{\lambda}_i$ pertenecientes a $\hat{\lambda}$ tal que minimizan $\sum_{n=1}^{n} |\hat{\lambda}_i - T_{ii}|$ son todos 0. En consecuencia la matriz $\hat{T}$ tendra la diagonal nula y el resto de valores $\hat{T}_{ij} = T_{ij}$.

$$P_\psi(U, T_1) = \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ \sqrt{2}/2 & -\sqrt{2}/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 1 & 4 \\ 0 & 0 & 2 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ \sqrt{2}/2 & -\sqrt{2}/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} = ... \tag{6}$$

$$... = \begin{pmatrix} 0 & \sqrt{2}/2 & 3\sqrt{2} \\ 0 & \sqrt{2}/2 & \sqrt{2} \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ \sqrt{2}/2 & -\sqrt{2}/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} = ... \tag{7}$$

$$... = \begin{pmatrix} 1/2 & -1/2 & 3\sqrt{2} \\ 1/2 & -1/2 & \sqrt{2} \\ 0 & 0 & 0 \end{pmatrix} \tag{8}$$

$$P_\psi(I,T_2) = \begin{pmatrix}1&0&0\\0&1&0\\0&0&1\end{pmatrix}\begin{pmatrix}0&-1&3\sqrt{2}\\0&0&\sqrt{2}\\0&0&0\end{pmatrix}\begin{pmatrix}1&0&0\\0&1&0\\0&0&1\end{pmatrix} = ... \tag{9}$$

$$... = \begin{pmatrix}0&-1&3\sqrt{2}\\0&0&\sqrt{2}\\0&0&0\end{pmatrix} \tag{10}$$

Por lo que vemos que:

$$P_\psi(U,T_1) = \begin{pmatrix}1/2&-1/2&3\sqrt{2}\\1/2&-1/2&\sqrt{2}\\0&0&0\end{pmatrix} \neq \begin{pmatrix}0&-1&3\sqrt{2}\\0&0&\sqrt{2}\\0&0&0\end{pmatrix} = P_\psi(I,T_2) \tag{11}$$

Luego:

$UT_1U^* = T_2$ no implica $P_\psi(U,T_1) = P_\psi(I,T_2)$.

7.3. Ejercicio 3.1.1.2

Tenemos que:

$U_1T_1U_1^* = U_2T_2U_2^* \iff (U_2^{-1})U_1T_1U_1^*(U_2^*)^{-1} = T_2 \iff$
$(U_2^*U_1)T_1(U_1^*U_2) = T_2$ (Por U_2 unitara).
Luego, definimos $U_3 = U_2^*U_1$.

Entonces, $U_3^{-1} = (U_2^*U_1)^{-1} = U_1^{-1}(U_2^*)^{-1} = U_1^{-1}(U_2^{-1})^{-1} = U_1^{-1}U_2 = U_1^*U_2$.
Ademas, como el producto de matrices unitarias da como resultado matrioces unitarias, U_3 es unitaria y $U_3^{-1} = U_3^*$. Por esto, se puede reescribir $(U_2^*U_1)T_1(U_1^*U_2)$ como $U_3T_1U_3^*$.

Tenemos $U_3T_1U_3^* = T_2$.

Luego:

$P_\psi(U_1,T_1) = P_\psi(U_2,T_2) \iff U_1\hat{T}_1U_1^* = U_2\hat{T}_2U_2^* \iff (U_2^{-1})U_1\hat{T}_1U_1^*(U_2^*)^{-1} = \hat{T}_2 \iff$
$(U_2^*U_1)\hat{T}_1(U_1^*U_2) = \hat{T}_2 \iff U_3\hat{T}_1U_3^* = \hat{T}_2 \iff U_3\hat{T}_1U_3^* = I\hat{T}_2I^*$.

Luego: $P_\psi(U_1,T_1) = P_\psi(U_3,T_1)$ si $P_\psi(U_2,T_2) = P_\psi(I,T_2)$.

Por lo que la expresion:

i) $U_1T_1U_1^* = U_2T_2U_2^*$ no implica $P_\psi(U_1, T_1) = P_\psi(U_2, T_2)$.

Se puede reescribir como:

ii) $U_3T_1U_3^* = T_2$ no implica $P_\psi(U_3, T_1) = P_\psi(I, T_2)$, con $U_3 = U_2^*U_1$.

Ahora; supongamos que $U_3T_1U_3^* = T_2$ si implica $P_\psi(U_3, T_1) = P_\psi(I, T_2)$, con $U_3 = U_2^*U_1$.
En este caso se deberia cumplir para cuales quiera matrices $U_3 \in M_{nxn}$ unitaria; $T_1, T_2 \in M_{nxn}$ triangulares superiores, sin embargo, tomando las matrices de 3.1.1.1 tenemos un contraejemplo, es decir que no se cumple iii), o sea, no se cumple ii) y por consecuencia se cumple i).

7.4. Ejercicio 3.1.3.1

Tomando $\lambda = 0$

$$P_\Psi(U,T) = \frac{1}{10}\begin{pmatrix}-3 & 4\\ 4 & 3\end{pmatrix}\begin{pmatrix}0 & -3\\ 0 & 0\end{pmatrix}\begin{pmatrix}-3 & 4\\ 4 & 3\end{pmatrix} \Longrightarrow P_\Psi(U,T) = \frac{1}{10}\begin{pmatrix}36 & 18\\ -48 & -36\end{pmatrix} \tag{12}$$

$$UTU^* = \frac{1}{10}\begin{pmatrix}-3 & 4\\ 4 & 3\end{pmatrix}\begin{pmatrix}1 & -3\\ 0 & 2\end{pmatrix}\begin{pmatrix}-3 & 4\\ 4 & 3\end{pmatrix} \Longrightarrow UTU^* = \frac{1}{10}\begin{pmatrix}77 & 39\\ -36 & -2\end{pmatrix} \tag{13}$$

$$\tilde{U}\tilde{T}\tilde{U}^* = \frac{1}{10}\begin{pmatrix}-4 & 3\\ 3 & 4\end{pmatrix}\begin{pmatrix}0 & -3\\ 0 & 0\end{pmatrix}\begin{pmatrix}-4 & 3\\ 3 & 4\end{pmatrix} \Longrightarrow \tilde{U}\tilde{T}\tilde{U}^* = \frac{1}{10}\begin{pmatrix}36 & 48\\ -27 & -36\end{pmatrix} \tag{14}$$

$$P_\Psi(U,T) - UTU^* = \frac{1}{10}\begin{pmatrix}-41 & -21\\ -12 & -34\end{pmatrix} \tag{15}$$

$$\tilde{U}\tilde{T}\tilde{U}^* - UTU^* = \frac{1}{10}\begin{pmatrix}-41 & -9\\ 9 & -34\end{pmatrix} \tag{16}$$

Tomando A = $P_\Psi(U,T) - UTU^*$ y $B = \tilde{U}\tilde{T}\tilde{U}^* - UTU^*$ tenemos que:

$\|P_\Psi(U,T) - UTU^*\| = \sqrt{tr(AA^*)} = \sqrt{(\frac{(41^2+21^2+12^2+34^2)}{10^2})}$

$\|\tilde{U}\tilde{T}\tilde{U}^* - UTU^*\| = \sqrt{tr(BB^*)} = \sqrt{(\frac{(41^2+2.(9)^2+34^2)}{10^2})}$

Como $\|P_\Psi(U,T) - UTU^*\| > \|\tilde{U}\tilde{T}\tilde{U}^* - UTU^*\|$

$\implies \|P_\Psi(U,T) - UTU^*\| \not\leqslant \|\tilde{U}\tilde{T}\tilde{U}^* - UTU^*\|$

7.5. Ejercicio 3.1.3.2

Supongamos que se cumple la siguiente proposición:
i) Dada A = UTU*, $P_\Psi(U,T)$ satisface $\|P_\Psi(U,T) - A\| \leqslant \|M - A\|\ \forall M \in \Psi$
Puesto que se está tomando un A arbitrario, la proposición es verdadera $\iff$ la misma se cumple para cualquier matriz A $\in \mathbb{C}^{n\times n}$ tal que A = UTU* con U $\in \mathbb{C}^{n\times n}$ unitaria y T $\in \mathbb{C}^{n\times n}$ triangular superior.

Ahora, en el caso de las matrices M_{2x2}, tomando las matrices del ejercicio 1, A = UTU* y M = $\tilde{U}\tilde{T}\tilde{U}^*$, tenemos un caso en el que $\|P_\Psi(U,T) - A\| \not\leqslant \|M - A\| \forall M \in \Psi$, siendo esto un contraejemplo, por lo que i) es falso y se cumple:

ii) Dada A = UTU*, $P_\Psi(U,T)$ no satisface $\|P_\Psi(U,T) - A\| \leqslant \|M - A\| \forall M \in \Psi$

7.6. Ejercicio 3.1.3.3

La conclusión anterior no contradice el teorema 3.1.3, pues este se satisface en el caso en el que la matriz M se construye como M = U$\hat{T}U^*$, notar que la matriz unitaria U es la misma que en A = UTU*.
En nuestro contraejemplo usamos M = $\tilde{U}\tilde{T}\tilde{U}^*$, donde U $\neq \tilde{U}$, por lo que no cumplimos con las condiciones para aplicar el teorema, llegando así a que la conclusión del ejercicio 2 no contradice el teorema 3.1.3.

7.7. Ejercicio 3.2

Pseudo Codigo:

Require: $\lambda = \{\lambda_1, \ldots, \lambda_n\}$
1: $Y \in \mathbb{R}^{n \times n}$ no-negativa elegida aleatoriamente.
2: repeat
3: Calcular la descomposición de $Y : Y = UTU^*$.
4 : $X := P_\Psi(U, T)$
5: $Y := X_+$
6: until $\|X - Y\| < \epsilon$

Las desventajas de este algoritmo son que el λ que se ingresa para cada valor complejo entonces tiene que encontrarse su conjugado, ya que de otra manera nunca habria solucion, tambien tiene que cumplir que la suma de cada entrada en total de positiva. En este algoritmo nuestro equipo realizo un enfoque mas rapido en el apartado del calculo de las permutaciones para la proyeccion de 4, ya que nuestro orden es $o(n^2)$ y no $o(n!)$ como lo seria se se hicieran todas las permutaciones y probasemos 1 por 1.

8. Ejercicios 4

8.1. Ejercicio 4.1.1

Tabla 1: Tabla de promedios de algoritmo 1 (En 100 iteraciones por cada N).

N	(i)	(t)	(α)
2	245	0.9s	76 %
3	187	1.1s	84 %
4	209	1.84s	85 %
5	276	3.55s	83 %
6	224	3.99s	89 %
7	242	5.4s	91 %
8	308	9.01s	86 %
10	407	19.42s	79 %
13	462	35.74s	80 %
20	683	120.84s	59 %

Tenemos que el comportamiento de (t) tiende a aumentar drasticamente para $N > 13$ pero no solamente por la cantidad de iteraciones debido al incremento de la dimension de la matriz si no que por la complejidad de las operaciones lleva mas tiempo de computo por cada iteracion.

Efectivamente e intuitivamente como se podria pensar las iteraciones (i) para el problema con $N > 13$ ya disparan las iteraciones debido a que por asi decirlo al tener una matriz mas grande estamos pidiendo mas requisitos a la matriz solucion por lo tanto hay que hacer mas operaciones para poder encontrarla desembocando en una cantidad mas elevada de iteraciones, esto tambien se debe a que por lo anterior en muchos de los casos no es posible encontrar la solucion buscada haciendo que el promedio de iteraciones incremente.

Como observamos en la tabla para (α) menores a 13 tenemos que la convergencia se comporta de forma regular con pequeñas fructruaciones en relacion a las dimensiones con las que opera, pero nuevamente cuando pasamos de el umbral de $N = 13$ dicha convergencia se ve afectada negativamente haceindo que baje un 20 % en realcion a los otros valores de N esto nos deja en claro lo mencionado anteriormente, que al agrandar la dimension la matriz solucion tiene que cumplir con mas requisitos que nosotros le pedimos y por ende como es de esperarse la convergencia se va a ver afectada mientras este N incremente.

8.2. Ejercicio 4.1.2

Tabla 2: Tabla de promedios de algoritmo 1 (En 100 iteraciones) con $\lambda = (3 - K, 1 + K, -1, -1, -1, -1)$ con $0 < K < 1$.

K	(i)	(t)	(α)
0,1	343	6.7s	98 %
0,2	376	7.37s	99 %
0,3	348	6.83s	96 %
0,4	321	6.33s	98 %
0,5	316	6.13s	96 %
0,6	359	6.94s	90 %
0,7	473	9,16s	71 %
0,8	578	11.26s	55 %
0,9	665	11.94s	43 %
0,9999	644	12.64s	44 %

Tenemos que el comportamiento de (t) tiende a ser regular para estas pruebas ya que en este caso no estamos cambiando dimensiones en cada una de ellas sin embargo las diferencias saltan a la vista cuando comparamos con el $N = 6$ de la tabla anterior el cual arroja un (t) % de $3{,}9s$ esto nos dice que esta configuracion de λ es mas dificil de operar que el promedio aleatorio.

Efectivamente vemos que (i) aumenta considerablemente cuando $K > 0,7$ esto se debe a que a medida que K crece esta configuracion de λ se vuelve bastante pretenciosa y por ende se tiene que iterar mas veces para llegar a dicha solucion lo cual nuevamente nos da un punto de contraste con el $N = 6$ de la otra tabla la cual en promedio maneja 224 iteraciones bastante alejado de lo que aqui ocurre.

Vemos que efectivamente la taza de convergencia acompaña lo antes descrito ya que se mantiene regular para $K < 0{,}7$ pero luego de esta barrera a medida que K aumenta la convergencia se ve afectada drasticamente haciendo que las iteraciones aumenten y por ende el tiempo de computo tambien, esto se debe a que como antes mencionamos cuando los K se acercan a 1,0 luego nos queda un vector λ aproximadamente $\lambda = (2, 2, -1, -1, -1, -1)$ y esta solucion en particular es bastante exigente de encontrar.

8.3. Ejercicio 4.2.1

Tabla 3: Tabla de promedios de algoritmo 2 (En 100 iteraciones por cada N).

N	(i)	(t)	(α)
2	7	0.066s	100 %
4	8	0.239s	100 %
6	9	0.72s	100 %
8	13	1.89s	100 %
10	59	15.67s	99 %

Tenemos que el comportamiento de (t) tiende a ser pequeño esto lo atribuimos a que nuestro algoritmo no funciona con funciones de permutacion y por ende en ningun lugar tiene orden $o(n!)$.

En general con las (i) pudimos observar que el promedio es pequeño debido a que los λ introducidos siempre se encuentran con sus respectivos conjugados y se cuida que la suma de todos ellos no se negativo eligiendo de forma al azar para que hallan menos negativos que positivos, dejando asi la posibilidad de que igualmente aparezca una suma que de negativa.

La convergencia (α) es sorprendentemente alta debido a lo antes descrito para (i) ademas de que se esta tratando con N relativamente pequeños entonces eso da resultado a dicha taza.

8.4. Ejercicio 4.2.1

Nuestra modificacion se basa en imponer que la matriz X luego de cada iteracion cumpla con el patron descrito Z haciendo aparecer 0 donde se planteo y luego en los lugares que no tiene que ir 0 obligatoriamente tenemos que lograr obtener valores $\phi \geq 0$, ademas de cumplir que la suma de la fila sea 1 para que dicha matriz termine siendo estocastica, por ende lo que hacemos es sumar cada entrada de una fila de la matriz X y luego a cada una de dichas entradas de la fila la dividimos por la suma haciendo asi que luego cuando se sume componenete a componenete el resultado sea 1, finalmente logramos resultados que salen por condicion de la norma de la diferencia de X e Y siendo valores bastante aproximados.

8.5. Ejemplo 4.2.2

Tomamos $\lambda = (1, 1, (0{,}29), (0{,}69), 1)$ el cual nos arroja luego de correr el algoritmo la matriz:

$$Y = \begin{bmatrix} 0,2671 & 0 & 0 & 0 & 0,7329 \\ 0 & 0,9882 & 0,0118 & 0 & 0 \\ 0 & 0 & 0,8106 & 0,1894 & 0 \\ 0 & 0 & 0 & 1,0000 & 0 \\ 0 & 0 & 0 & 0,2956 & 0,7044 \end{bmatrix}$$

La cual da como resultado autovalores $\lambda = (1, (0,98), (0,26), (0,70), (0,97))$